

1. ¿Cómo se asegura el gradiente descendente de encontrar el mínimo global en regresión lineal?

En el caso particular de la regresión lineal, vimos que su función de costo es el error cuadrático medio (MSE), esta función de costo es convexa respecto a los parámetros.

Una función convexa tiene una sola región de mínimo y no tiene mínimos locales distintos al mínimo global.

El gradiente descendente, al ir bajando en la dirección de máxima pendiente negativa, está garantizado a converger al mínimo global.

La función de costo

$$J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$$

El hessiano es:

$$H = \frac{1}{m} X^T X$$

$X^T X$ es siempre positivo semidefinido, lo cual implica convexidad.

Entonces, en la regresión lineal, no hay mínimos locales, por lo que el gradiente descendente siempre converge al mínimo global.

2. ¿Puede el gradiente descendente llegar a un punto silla en regresión lineal?



Los puntos silla aparecen en funciones no convexas, donde hay direcciones con curvatura positiva y otras con curvatura negativa.

En regresión lineal, la función de costo no tiene curvatura negativa en ningún punto: todas las direcciones tienen curvatura positiva o nula (por la convexidad).

Por tanto, no existen puntos silla en la superficie de costo de una regresión lineal.

Nota: En redes neuronales u otros modelos no lineales, sí existen muchos puntos silla y mínimos locales. Ahí el gradiente descendente puede atascarse o moverse lentamente cerca de un punto silla, pero esto no ocurre en regresión lineal.

Te dejo algunas imágenes de superficies de costos convexas (regresión lineal):



3. Las variables que son interacciones, hacen que una regresión lineal deje de ser lineal?

En regresión lineal, “lineal” se refiere a los parámetros (β) y no a las variables originales.

Una regresión lineal tiene la forma:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m$$

Es lineal en los β porque cada β_j multiplica directamente a su variable y se suman entre sí (no hay potencias ni productos de β sí).

Qué pasa si agrego términos de interacción?

Por ejemplo, si incluyes un término $x_1 \times x_2$:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 (x_1 x_2)$$

Sigue siendo una regresión lineal. Porque el modelo sigue siendo lineal en los parámetros $\beta_0, \beta_1, \beta_2, \beta_3$

4. En la regresión lineal, una de las suposiciones, es que las variables de entrada deben ser independientes, pero si metemos variables que están muy correlacionadas pueden agregar “ruido” o “incertidumbre”

Cuando metes variables muy correlacionadas entre sí:

- El modelo no puede distinguir bien cuál de esas variables está aportando qué, porque cambian juntas.

- Esto hace que el modelo tenga más incertidumbre en las estimaciones de los β
- A esto se le llama multicolinealidad, y su efecto es que:
 - los coeficientes estimados pueden variar mucho con pequeños cambios en los datos
 - puede parecer que las variables “aportan poco” aunque en realidad sí sean relevantes.

Ejemplo:

Queremos predecir la calificación de estudiantes (y) usando variables de entrada: x_1 (horas estudiadas), x_2 (ejercicios resueltos), x_3 (color de los cuadernos).

Qué pasa si meto una variable muy correlacionada?

Si agrego x_2 (ejercicios resueltos), y resulta que está fuertemente correlacionada con x_1 (los que estudian más, resuelven más ejercicios):

$$x_2 \approx 4 \cdot x_1$$

Entonces el modelo intenta repartir el efecto de x_1 , entre x_1 y x_2 :

$$y \approx \alpha + \beta_1 x_1 + \beta_2 x_2 + \epsilon$$

Pero como x_1 y x_2 se mueven casi juntos, el modelo no puede saber bien a cuál darle el mérito.

El resultado es:

Los β_1 , β_2 , salen con mucha intertidumbre